

**Universidad
Tres culturas**

**Materia:
Minería de datos**

**Tema:
Proyecto Final**

**Carrera:
Ingeniería en Sistemas Computacionales**

**Profesor:
Morales Cardoso Angel Uriel**

**Alumno:
Campos Sanchez Victor Abraham
Ocampos Cruz Jose Juan Carlos
Jimenez Morales Diego
Tellez Celaya Fernando**

Análisis y segmentación del comportamiento de compra de clientes mediante técnicas de minería de datos

1. Introducción

El comercio minorista genera información sobre las características y preferencias de sus clientes, como edad, género, categoría de producto, monto de compra, calificación, historial de compras, uso de descuentos y frecuencia de compra. Analizar estas variables permite identificar perfiles de consumidores y encontrar patrones que apoyen decisiones de marketing, fidelización y segmentación.

Para este proyecto se utilizó el Customer Shopping Trends Dataset, disponible en Kaggle (Banerjee, s. f.). El conjunto contiene 3,900 registros y 19 variables relacionadas con el comportamiento de compra. Se eligió porque ofrece suficientes variables numéricas y categóricas para combinar análisis exploratorio, clustering con K-Means y un segundo componente de clasificación.

2. Planteamiento del problema

2.1 Contexto del problema

La situación de análisis consiste en comprender si existen grupos de clientes con comportamientos diferenciados y evaluar si las características disponibles permiten predecir el estado de suscripción de un cliente.

2.2 Pregunta principal de análisis

¿Qué perfiles de clientes pueden identificarse a partir de su edad, monto de compra, calificación e historial de compras, y qué tan útil resulta un modelo predictivo para estimar si un cliente cuenta con suscripción?

2.3 Justificación

La segmentación permite comprender grupos de consumidores sin depender de etiquetas previamente definidas, mientras que la analítica predictiva permite contrastar si las variables disponibles contienen patrones útiles para anticipar una característica comercial. Esta combinación facilita traducir los resultados técnicos en posibles acciones de negocio.

3. Objetivos

3.1 Objetivo general

Analizar el comportamiento de compra de los clientes mediante técnicas de minería de datos para descubrir patrones, segmentar perfiles de consumidores con K-Means y evaluar un modelo predictivo orientado al estado de suscripción.

3.2 Objetivos específicos

1. Examinar y preparar el dataset mediante revisión de valores faltantes, duplicados, tipos de datos, valores atípicos y estadística descriptiva.
2. Identificar perfiles de consumidores utilizando K-Means a partir de variables numéricas relevantes y justificar el número de grupos mediante el método del codo.
3. Aplicar regresión logística para predecir el estado de suscripción y evaluar su desempeño mediante exactitud, matriz de confusión, precision, recall y F1-score.

4. Selección y descripción del dataset

4.1 Ficha técnica

Elemento	Descripción
Nombre	Customer Shopping Trends Dataset
Fuente	Kaggle Datasets
Autor publicado en Kaggle	Sourav Banerjee
Registros utilizados	3,900
Columnas	19
Formato	CSV
Tema	Comportamiento de compra y preferencias de clientes
Licencia indicada en Kaggle	Other (specified in description)
Naturaleza de los datos	Dataset sintético con fines educativos y de práctica de análisis/ML

4.2 Diccionario de datos

Columna	Tipo	Significado
Customer ID	int64	Identificador único de cada cliente.
Age	int64	Edad del cliente.
Gender	object	Género registrado del cliente.
Item Purchased	object	Artículo comprado.
Category	object	Categoría del producto adquirido.
Purchase Amount (USD)	int64	Monto de la compra expresado en dólares estadounidenses.
Location	object	Ubicación asociada con la compra.
Size	object	Talla del producto adquirido.
Color	object	Color del producto.
Season	object	Temporada asociada con la compra.
Review Rating	float64	Calificación proporcionada por el cliente.
Subscription Status	object	Indica si el cliente tiene suscripción (Yes/No).

Payment Method	object	Método de pago registrado en la compra.
Shipping Type	object	Tipo de envío utilizado.
Discount Applied	object	Indica si se aplicó descuento (Yes/No).
Promo Code Used	object	Indica si se utilizó un código promocional (Yes/No).
Previous Purchases	int64	Número de compras anteriores realizadas por el cliente.
Preferred Payment Method	object	Método de pago preferido registrado para el cliente.
Frequency of Purchases	object	Frecuencia declarada de compra.

5. Metodología y preparación de datos

Todo el procesamiento y análisis se realizó en Google Colab utilizando Python, pandas, matplotlib y scikit-learn. En el notebook se efectuaron la carga del CSV, la revisión de calidad, el análisis exploratorio, la estandarización de variables, el clustering con K-Means y el modelo de regresión logística. En este reporte se documentan la metodología, los resultados y las interpretaciones obtenidas en Colab.

5.1 Limpieza y control de calidad

Revisión	Resultado
Registros iniciales	3,900
Columnas	19
Valores faltantes	0
Registros duplicados	0
Registros después de limpieza	3,900
Acciones realizadas	Revisión de nulos, duplicados y tipos; eliminación de espacios innecesarios en variables de texto.

La revisión mediante el criterio del rango intercuartílico (IQR) en Age, Purchase Amount (USD), Review Rating y Previous Purchases no identificó valores atípicos fuera de 1.5 veces el IQR. Por esa razón no fue necesario eliminar observaciones por este criterio.

Para K-Means se aplicó StandardScaler a las variables numéricas, ya que cada variable utiliza escalas diferentes. Esta estandarización evita que el monto de compra o la edad dominen la distancia únicamente por el tamaño de sus valores.

6. Análisis exploratorio de datos

6.1 Estadística descriptiva


Variable	Media	Mediana	Moda	Desv. est.	Mín.	Máx.
Edad	44.07	44.00	69.00	15.21	18.00	70.00
Monto de compra (USD)	59.76	60.00	32.00	23.69	20.00	100.00
Calificación	3.75	3.70	3.40	0.72	2.50	5.00
Compras anteriores	25.35	25.00	31.00	14.45	1.00	50.00

La edad promedio es de 44.07 años y la mediana es 44, mientras que el monto promedio de compra es 59.76 USD y su mediana es 60 USD. La calificación promedio es 3.75 sobre 5 y los clientes registran, en promedio, 25.35 compras anteriores. La cercanía entre media y mediana en edad y monto de compra sugiere una distribución sin un sesgo central extremo.


6.2 Hallazgos descriptivos generales

Aspecto	Resultado
Género	Male: 2,652 (68.0%); Female: 1,248 (32.0%).
Categoría más frecuente	Clothing: 1,737 compras (44.5%).
Segunda categoría	Accessories: 1,240 compras (31.8%).
Suscripción	No: 2,847 (73.0%); Yes: 1,053 (27.0%).
Temporada con más compras	Spring: 999 registros.
Temporada con menos compras	Summer: 955 registros.
Frecuencia más común	Every 3 Months: 584 registros.
Mayor compra promedio por categoría	Footwear: 60.26 USD.
Mayor calificación promedio por categoría	Footwear: 3.79.


6.3 Visualizaciones e interpretación



Interpretación: Las edades se distribuyen entre 18 y 70 años, con una media de 44.07 y mediana de 44. El dataset incluye clientes de distintos rangos de edad, lo cual permite que esta variable contribuya a la segmentación.




Interpretación: Clothing concentra 1,737 registros y es la categoría dominante, seguida por Accessories con 1,240. Footwear y Outerwear tienen menor presencia.




Interpretación: Los montos medios son relativamente cercanos entre categorías.


Footwear presenta el promedio más alto (60.26 USD), mientras Outerwear tiene el menor (57.17 USD).



Interpretación: El 72.99% de los clientes no tiene suscripción y el 27.01% sí. Este desequilibrio se consideró en el modelo predictivo mediante ponderación de clases y una comparación contra la clase mayoritaria.



Interpretación: Las categorías de frecuencia se encuentran relativamente equilibradas. Every 3 Months es la más frecuente con 584 registros y Weekly la menor entre las categorías mostradas con 539.



Interpretación: Las correlaciones lineales son muy bajas. La mayor magnitud observada es cercana a 0.04, por lo que edad, monto de compra, calificación y compras anteriores no presentan relaciones lineales fuertes entre sí.


7. Modelo no supervisado: K-Means

7.1 Variables seleccionadas y justificación

Se seleccionaron Age, Purchase Amount (USD), Review Rating y Previous Purchases porque representan dimensiones diferentes del comportamiento del cliente: perfil demográfico, nivel de gasto, valoración de la experiencia e historial de compra. Todas son numéricas y pueden estandarizarse de forma directa.

No está incluido Customer ID porque solo identifica registros. Las variables categóricas no se incorporaron en este K-Means para mantener una segmentación basada en cuatro medidas cuantitativas directamente interpretables.

7.2 Selección del número de clusters



Interpretación: La curva no presenta un quiebre extremadamente pronunciado; sin embargo, alrededor de $K=4$ comienza una reducción más gradual de la ganancia relativa de inercia. Se eligió $K=4$ como una solución parsimoniosa (es decir, el menor número de grupos posibles para explicar datos.) que permite obtener perfiles diferenciados y fáciles de interpretar sin fragmentar excesivamente la muestra.

La elección de $K=4$ se tomó como un equilibrio entre reducción de inercia e interpretabilidad. Debido a que el codo no es completamente marcado, esta elección debe considerarse una decisión analítica razonada y no una única solución posible.

7.3 Resultados de los clusters

Cluster	Perfil	Cientes	Edad	Compra USD	Rating	Compras previas
0	Cientes de alta edad de alto gasto y buena valoración	966	56.22	82.08	3.96	26.76
1	Cientes jóvenes satisfechos de gasto medio	969	31.33	54.86	4.43	24.98
2	Cientes jóvenes de gasto medio-alto y menor satisfacción	986	32.59	64.76	3.09	22.44
3	Cientes de alta edad de bajo gasto	979	56.26	37.57	3.54	27.26


Cluster 0 - Clientes de alta edad de alto gasto y buena valoración: Agrupa 966 clientes con edad promedio de 56.22 años y el monto de compra más alto, 82.08 USD. Su

calificación promedio es 3.96 y registran 26.76 compras anteriores. Es el segmento de mayor gasto.

Cluster 1 - Clientes jóvenes satisfechos de gasto medio: Incluye 969 clientes, con edad promedio de 31.33 años. El gasto medio es 54.86 USD y presenta la calificación más alta de todos los grupos, 4.43. Puede considerarse un grupo joven con alta satisfacción.

Cluster 2 - Clientes jóvenes de gasto medio-alto y menor satisfacción: Está formado por 986 clientes con edad promedio de 32.59 años y gasto promedio de 64.76 USD. Su calificación media, 3.09, es la más baja, por lo que combina un gasto moderado-alto con menor satisfacción.

Cluster 3 - Clientes de alta edad de bajo gasto: Agrupa 979 clientes con edad promedio de 56.26 años. Tiene el menor monto promedio de compra, 37.57 USD, y una calificación de 3.54. Destaca por un historial promedio de 27.26 compras anteriores.



Interpretación: La visualización ayuda a observar la separación de perfiles en dos variables centrales. Los resultados completos del clustering dependen además de Review Rating y Previous Purchases, por lo que la gráfica bidimensional es una representación parcial de la segmentación.

8. Segundo componente aplicado: analítica predictiva

8.1 Objetivo del modelo

Se utilizó regresión logística para predecir Subscription Status (Yes/No). Las variables predictoras fueron Age, Gender, Category, Purchase Amount (USD), Season, Review Rating, Discount Applied, Previous Purchases y Frequency of Purchases.


Las variables numéricas se estandarizaron con StandardScaler y las categóricas se transformaron con OneHotEncoder. El conjunto se dividió de forma estratificada en 70% para entrenamiento (2,730 registros) y 30% para prueba (1,170 registros). Debido al desequilibrio entre No y Yes, la regresión logística utilizó `class_weight='balanced'`.

8.2 Resultados del modelo

Métrica	Resultado
Exactitud del modelo	84.19%
Referencia: predecir siempre la clase mayoritaria	72.99%
Casos de prueba	1,170
No reales	854
Yes reales	316
No correctamente identificados	669
Yes correctamente identificados	316
No clasificados erróneamente como Yes	185
Yes clasificados erróneamente como No	0

La exactitud de 84.19% supera en 11.20 puntos porcentuales a la referencia de 72.99% que se obtendría al clasificar todos los casos como la clase mayoritaria. Esto indica que el modelo utiliza información adicional de las variables predictoras y no se limita a repetir la clase más frecuente.

Para la clase Yes, el recall fue 1.00: el modelo identificó los 316 clientes suscritos del conjunto de prueba. Sin embargo, la precision de Yes fue 0.63, debido a 185 falsos positivos. Para la clase No, la precision fue 1.00 y el recall 0.78. El F1-score fue 0.88 para No y 0.77 para Yes.



Interpretación: El modelo detectó todos los casos Yes, pero clasificó 185 clientes No como Yes. Por tanto, su fortaleza es la sensibilidad para detectar suscripciones, mientras que su principal error consiste en generar falsos positivos.

8.3 Ejemplos de predicción

Caso	Edad	Género	Categoría	Compra USD	Descuento	Frecuencia	Real	Predicho
1	18	Female	Accessories	31	No	Weekly	No	No
2	32	Male	Accessories	63	Yes	Fortnightly	Yes	Yes
3	69	Male	Accessories	78	Yes	Monthly	Yes	Yes
4	49	Male	Clothing	96	No	Every 3 Months	No	No
5	26	Male	Outerwear	49	Yes	Annually	Yes	Yes

Los cinco ejemplos mostrados coincidieron con el estado real. Sin embargo, estos casos son únicamente ilustrativos; la fiabilidad general debe evaluarse con los 1,170 registros de prueba y no solo con cinco observaciones.

9. Conclusiones y recomendaciones

9.1 Conclusiones

1. El dataset permitió realizar un análisis completo sin eliminar registros: los 3,900 casos se conservaron porque no se detectaron valores faltantes ni duplicados y las variables numéricas revisadas no presentaron valores atípicos bajo el criterio IQR.
2. El cliente promedio tiene 44.07 años, realiza una compra de 59.76 USD, otorga una calificación de 3.75 y registra 25.35 compras anteriores, lo que proporciona un perfil central útil para comparar los segmentos.
3. Clothing concentra la mayor cantidad de compras con 1,737 registros (44.5%), mientras que Footwear presenta el mayor monto promedio de compra (60.26 USD) y la mejor calificación media (3.79).

4. Las variables numéricas presentan correlaciones lineales muy débiles; por ejemplo, la relación entre edad y monto de compra es -0.010. Esto indica que ninguna de las variables analizadas explica linealmente por sí sola el comportamiento de las demás.
5. K-Means permitió identificar cuatro perfiles diferenciados. Los contrastes más claros aparecen en edad, monto de compra y calificación: existen clientes de alta edad de alto gasto, jóvenes con alta satisfacción, jóvenes con menor satisfacción y clientes maduros de bajo gasto.
6. El Cluster 0 representa el segmento de mayor gasto, con un promedio de 82.08 USD, mientras que el Cluster 3 tiene el gasto promedio más bajo, 37.57 USD. Esta diferencia puede servir para diseñar estrategias comerciales diferenciadas.
7. La regresión logística alcanzó 84.19% de exactitud, superior al 72.99% de una predicción basada únicamente en la clase mayoritaria, por lo que las variables utilizadas contienen patrones útiles para estimar el estado de suscripción.
8. El modelo identificó todos los clientes suscritos del conjunto de prueba (recall de 1.00 para Yes), pero produjo 185 falsos positivos. Por lo tanto, su resultado debe utilizarse como apoyo analítico y no como decisión automática.

9.2 Recomendaciones prácticas

1. Diseñar campañas diferenciadas por cluster. El Cluster 0 puede recibir estrategias de fidelización, beneficios premium o recomendaciones de productos de mayor valor, debido a su gasto promedio elevado.

2. Priorizar acciones de mejora de experiencia para el Cluster 2, ya que combina un gasto relativamente alto con la calificación promedio más baja. Conviene investigar causas de insatisfacción antes de enfocar únicamente promociones.
3. Desarrollar acciones de conversión a suscripción para perfiles con alta satisfacción, especialmente el Cluster 1. Su calificación media de 4.43 puede representar una oportunidad para programas de membresía o lealtad.
4. Utilizar el modelo de suscripción como herramienta de priorización y no como regla definitiva. Debido a los falsos positivos, cualquier campaña basada en la predicción debería validarse con pruebas comerciales y seguimiento de resultados.

10. Limitaciones y mejoras posibles

10.1 Limitaciones del dataset

- El dataset es sintético y fue creado con fines educativos (Banerjee, s. f.); por ello, los patrones encontrados no deben generalizarse directamente a una población comercial real.
- La variable Gender contiene únicamente las categorías disponibles en el archivo, lo que limita la representación de otras identidades.
- No existe una variable de fecha de transacción, por lo que no se pueden analizar tendencias temporales, estacionalidad histórica ni cambios de comportamiento a lo largo del tiempo.
- La información utiliza montos en USD y ubicaciones asociadas con Estados Unidos, por lo que la interpretación debe mantenerse dentro del contexto simulado del dataset.
- El estado de suscripción está desbalanceado: aproximadamente 73% corresponde a No y 27% a Yes.

10.2 Limitaciones de los modelos

- K-Means depende de la selección y escala de las variables. En este análisis se utilizaron cuatro variables numéricas; otros atributos podrían producir una segmentación diferente.
- El método del codo no mostró un quiebre completamente pronunciado, por lo que $K=4$ es una solución interpretable y razonable, pero no necesariamente la única posible.
- La visualización bidimensional de clusters utiliza edad y monto de compra, aunque el algoritmo también considera calificación y compras anteriores.
- La regresión logística es un modelo lineal en el espacio transformado y puede no capturar relaciones complejas entre variables.
- El modelo predictivo mostró falsos positivos para la clase Yes, por lo que no debe utilizarse sin validación externa en decisiones reales.

10.3 Mejoras si hubiera más tiempo o mejores datos

- Validar el número de clusters con métricas adicionales y comparar K-Means con clustering jerárquico u otros métodos.
- Utilizar datos reales de transacciones con fechas, canales de venta, ingresos, recurrencia monetaria y respuesta a campañas.
- Comparar la regresión logística con modelos como árbol de decisión, random forest o MLPClassifier, utilizando validación cruzada.
- Ajustar el umbral de clasificación y evaluar métricas orientadas a negocio para reducir falsos positivos según el costo real de una campaña.
- Incorporar análisis temporal para estudiar evolución de compras, temporadas y permanencia de los clientes.

11. Evidencia de trabajo en equipo

Integrante	Rol	Actividades
Campos Sanchez Victor Abraham	Líder de proyecto	Coordinación, planteamiento del problema y revisión final.
Ocampo Cruz Jose Juan Carlos	Limpieza / ETL	Carga, revisión, limpieza y generación del dataset limpio.
Jimenez Morales Diego	Modelos	K-Means, método del codo y regresión logística.
Tellez Celaya Alan Fernando	Visualizaciones y reporte	Gráficas, interpretación, conclusiones y presentación.

12. Referencias

Banerjee, S. (s. f.). Customer shopping trends dataset [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/iamsouravbanerjee/customer-shopping-trends-dataset>